

MINI-PROJET

Des données synthétiques (n=20 observations) simulant une relation linéaire entre une variable réponse y et p=20 variables explicatives ont été générées afin de comparer la performance prédictive de deux méthodes de régression réguliarisée : Ridge (pénalisation L2) et Lasso (pénalisation L1). La matrice des prédicteurs $X \in \mathbb{R}^{n \times p}$, est constituée de variables aléatoires indépendantes suivant une loi normale standard $\mathcal{N}(0,1)$. Le vecteur de coefficients $\beta \in \mathbb{R}^p$ est défini de manière parcimonieuse : seuls les k=8 premiers coefficients sont non nuls, tirés selon une loi $\mathcal{N}(0,1)$, les autres étant fixés à zéro. Le bruit additif $\varepsilon \sim \mathcal{N}(0,\sigma^2)$, avec $\sigma=1.0$, est ajouté à la réponse. Pour chaque valeur du paramètre de régularisation λ , les modèles Ridge et Lasso sont entraînés sur un sous-échantillon aléatoire, puis évalués sur un ensemble test à l'aide de la racine de l'erreur quadratique moyenne (RMSE). L'expérience est répétée 50 fois pour chaque valeur de λ , et la figure finale présente la RMSE moyenne observée, mettant en évidence les différences de comportement entre les deux approches. Le code source de ce mini-projet est disponible sur GitHub à l'adresse suivante : https://github.com/Saadem/Mini-Projet-IFT-7021.git

La figure révèle que, pour de faibles valeurs de λ , les modèles Ridge et Lasso surajustent les données, ce qui se traduit par une RMSE élevée. À mesure que λ augmente, la régularisation améliore la performance jusqu'à un point optimal, au-delà duquel l'erreur remonte en raison d'un sous-ajustement. Le Lasso, en sélectionnant automatiquement les variables pertinentes, obtient de meilleurs résultats dans cette zone optimale, ce qui reflète bien la nature parcimonieuse du modèle simulé. Ridge, qui conserve tous les prédicteurs, présente une RMSE légèrement plus élevée dans ce contexte.

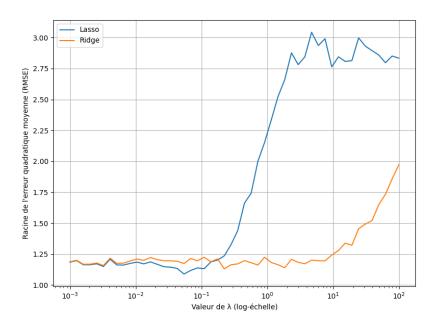


FIGURE 1 – RMSE movenne en fonction de la régularisation λ pour Ridge et Lasso.