

MINI-PROJET

Des données synthétiques ($n = 20$ observations) simulant une relation linéaire entre une variable réponse y et $p = 20$ variables explicatives ont été générées afin de comparer la performance prédictive de deux méthodes de régression régularisée : Ridge (pénalisation L2) et Lasso (pénalisation L1). La matrice des prédicteurs $X \in \mathbb{R}^{n \times p}$, est constituée de variables aléatoires indépendantes suivant une loi normale standard $\mathcal{N}(0, 1)$. Le vecteur de coefficients $\beta \in \mathbb{R}^p$ est défini de manière parcimonieuse : seuls les $k = 8$ premiers coefficients sont non nuls, tirés selon une loi $\mathcal{N}(0, 1)$, les autres étant fixés à zéro. Le bruit additif $\varepsilon \sim \mathcal{N}(0, \sigma^2)$, avec $\sigma = 1.0$, est ajouté à la réponse. Pour chaque valeur du paramètre de régularisation λ , les modèles Ridge et Lasso sont entraînés sur un sous-échantillon aléatoire, puis évalués sur un ensemble test à l'aide de la racine de l'erreur quadratique moyenne (RMSE). L'expérience est répétée 50 fois pour chaque valeur de λ , et la figure finale présente la RMSE moyenne observée, mettant en évidence les différences de comportement entre les deux approches. Le code source de ce mini-projet est disponible sur GitHub à l'adresse suivante : <https://github.com/Saadem/Mini-Projet-IFT-7021.git>

La figure ci dessous révèle que, pour de très faibles valeurs de λ , les modèles Ridge et Lasso affichent une RMSE faible et très similaire, en raison d'une régularisation quasi absente. À mesure que λ augmente, la performance se maintient un temps, puis se détériore rapidement sous l'effet d'une pénalisation excessive. Dans la zone intermédiaire, Lasso surpasse Ridge grâce à sa capacité à éliminer les variables non pertinentes. Toutefois, lorsque λ devient très grand, les deux modèles voient leur RMSE augmenter fortement et leurs performances tendent à redevenir similaires, traduisant un sous-ajustement marqué dans les deux cas.




FIGURE 1 – RMSE moyenne en fonction de la régularisation λ pour Ridge et Lasso.